
Master Big Data

Examan 2026

Sujet 3 : Le Gardien de la Donnée

Data Quality Framework Distribué sur le Dataset NYC Yellow Taxi

Dataset	NYC Yellow Taxi — Janvier 2023
Volume traité	3 066 766 lignes
Outil	Apache Spark 4.0 + PySpark (Google Colab)
Cas d'usage	Filtre anti-erreurs facturation SMELEC
Année	2026

1. Introduction et contexte

Dans un environnement Big Data, la qualité de la donnée constitue le premier verrou de toute prise de décision fiable. Ce projet a pour objectif de concevoir un moteur de validation de données distribué (Data Quality Framework) capable de traiter des volumes massifs, en utilisant Apache Spark sur le dataset NYC Yellow Taxi de janvier 2023, composé de 3 066 766 enregistrements.

1.1 Cas d'usage : La SMELEC et la fiabilité de la facturation

La Société Mauritanienne d'Electricité (SMELEC) collecte des millions de relevés de compteurs chaque mois. Une valeur aberrante — par exemple un compteur affichant 5 000 kWh en une journée suite à une panne technique — peut déclencher une facturation erronée et provoquer des réclamations. Ce pipeline de nettoyage, appliqué ici aux tarifs de taxi, se transpose directement au contexte SMELEC pour bloquer automatiquement toute valeur incohérente avant qu'elle n'atteigne le système de facturation.

1.2 Objectifs

- Profiler l'ensemble du dataset en une seule passe Spark (moyenne, écart-type, quartiles).
 - Détecter les valeurs aberrantes par la méthode statistique du Z-Score ($Z = (x - \mu) / \sigma$).
 - Nettoyer les données avec des filtres logiques sur les incohérences physiques.
 - Analyser et quantifier l'impact statistique du nettoyage (erreur induite par la non-qualité).
 - Mesurer les performances du pipeline : CPU, RAM, I/O et temps d'exécution Spark.
-

2. Étape 1 — Profilage des données (une seule passe Spark)

2.1 Statistiques descriptives — 3 066 766 lignes

Statistique	fare_amount (\$)	trip_distance (mi)	passenger_count	tip_amount (\$)	speed (km/h)
Count	3 066 766	3 066 766	2 995 023	3 066 766	3 065 648
Moyenne	18.37	3.85	1.36	3.37	25.33
Écart-type	17.81	249.58	0.90	3.83	2 895.03
Min	-900.0	0.0	0.0	-96.22	-15.95
25%	8.6	1.06	1.0	1.0	12.57
Médiane	12.8	1.8	1.0	2.73	16.46
75%	20.5	3.33	1.0	4.2	22.71
Max	1 160.1	258 928	9.0	380.8	4 167 034

2.2 Valeurs manquantes (NULL / NaN)

Colonne	fare_amount	trip_distance	passenger_count	speed_kmh
Valeurs NULL	0	0	71 743	1 118

2.3 Anomalies détectées lors du profilage

- fare_amount min = -900 \$: tarifs négatifs impossibles, erreurs d'encodage ou remboursements mal saisis.
- trip_distance max = 258 928 km : équivalent à 6 fois le tour de la Terre, bug GPS ou saisie manuelle erronée.
- speed_kmh max = 4 167 034 km/h : 13 fois la vitesse du son, résulte d'une durée proche de zéro.
- 71 743 NULL dans passenger_count (2.3%) : données non renseignées lors de la prise en charge.

3. Étape 2 — Détection des outliers par Z-Score

3.1 Formule appliquée

$$Z = (x - \mu) / \sigma \rightarrow \text{Si } |Z| > 3 : \text{valeur aberrante}$$

Le seuil $|Z| > 3$ correspond, pour une distribution normale, à moins de 0.3% des valeurs, soit uniquement les cas statistiquement extrêmes.

3.2 Résultats obtenus

Colonne analysée	Outliers détectés	Pourcentage	Statut
fare_amount	35 090 lignes	1.14%	Aberrant
trip_distance	67 lignes	0.00%	Aberrant
Total outliers	35 154 lignes	1.15%	À rejeter

Sur 3 066 766 trajets, 99.8% des outliers proviennent de fare_amount. Appliqué à la SMELEC, cela signifie que sur 1 million de relevés, environ 11 400 facturations seraient erronées sans ce filtre.

4. Étape 3 — Nettoyage des Dirty Data

4.1 Règles de filtrage appliquées

#	Règle métier	Condition	Justification	Type
1	Tarif positif	fare_amount > 0	Tarif négatif = erreur encodage	Logique
2	Distance positive	trip_distance > 0	0 km avec tarif = incohérent	Logique
3	Vitesse physique	0 < speed < 200 km/h	Au-delà : physiquement impossible	Physique
4	Durée valide	1 min ≤ durée ≤ 6 h	Trop court/long = bug capteur	Physique
5	Passagers valides	1 ≤ passagers ≤ 6	0 ou >6 = erreur de saisie	Logique

4.2 Résultats du nettoyage

Indicateur	Valeur
Lignes avant nettoyage	3 066 766
Lignes après nettoyage	2 847 679
Lignes rejetées	219 087
Taux de rejet global	7.14%
Temps de nettoyage Spark	12.65 secondes

4.3 Gestion des valeurs NULL

Pour les 71 743 NULL de passenger_count et les 1 118 NULL de speed_kmh, la stratégie choisie est la suppression (dropna) sur les colonnes critiques. Le faible taux de NULL (2.3%) ne compromet pas la représentativité du dataset.

5. Étape 4 — Analyse comparative Avant / Après nettoyage

Indicateur	AVANT nettoyage	APRÈS nettoyage	Δ Erreur
Moyenne fare_amount	\$18.37	\$17.80	3.08%
Écart-type fare_amount	\$17.81	\$14.82	—
Variance fare_amount	\$317.12	\$219.55	30.77%
Moyenne trip_distance	3.85 mi	3.27 mi	—

5.1 Interprétation — Garbage In, Garbage Out

- Erreur sur la moyenne des tarifs : +3.08%. Toute analyse de rentabilité bâtie sur données brutes surestimait systématiquement les recettes de 3%.
 - Surestimation de la variance : +30.77%. La variance était gonflée d'un tiers, faussant tous les modèles statistiques ou prédictifs.
 - Transposé à la SMELEC : une surestimation de 3% de la consommation moyenne représente, à l'échelle nationale, des millions d'Ouguiyas de surfacturation systématique.
-

6. Étape 5 — Taux de rejet et biais de sélection

6.1 Répartition horaire des outliers

Heure	Outliers	Heure	Outliers	Heure	Outliers	Heure	Outliers
00h	1 020	06h	1 196	12h	1 689	18h	1 816
01h	557	07h	1 392	13h	1 988	19h	1 759
02h	357	08h	1 115	14h	2 732	20h	1 566
03h	360	09h	1 192	15h	2 747	21h	1 438
04h	474	10h	1 396	16h	2 728	22h	1 534
05h	696	11h	1 434	17h	2 348	23h	1 620

Les tranches 14h-16h concentrent le plus d'outliers (~2 730/heure), soit 2.7x plus que les heures creuses (2h-4h). Ce biais temporel indique une surcharge des systèmes de traitement aux heures de pointe, et non des pannes ponctuelles de capteurs.

6.2 Répartition par VendorID — Biais capteur

VendorID	Outliers	Part du total
Vendor 1 (Creative Mobile)	6 268	17.8%
Vendor 2 (VeriFone)	28 886	82.2%

Constat majeur : le Vendor 2 génère 82.2% des outliers malgré un volume de trajets probablement comparable. Ce biais de capteur systématique signale un problème matériel ou logiciel structurel. Transposé à la SMELEC : cela équivaldrait à identifier une marque de compteur défaillante nécessitant un recalibrage ou remplacement prioritaire.

7. Analyse de performance — CPU / RAM / I/O

7.1 Ressources système mesurées

Ressource	Valeur mesurée	Commentaire
RAM totale	12.7 Go	Cluster Google Colab standard
RAM utilisée	3.9 Go	32% de la RAM totale consommée
RAM processus Spark	113 Mo	Empreinte légère du driver Spark
Cœurs CPU	2 cœurs	Architecture dual-core Colab
Utilisation CPU	54.8%	Charge modérée, pipeline bien parallélisé
Temps nettoyage	12.65 s	Sur 3 066 766 lignes — $O(n)$

7.2 Benchmark de requête complexe (SELECT AVG + GROUP BY)

Opération	Dataset brut	Dataset nettoyé	Différence
AVG fare + GROUP BY VendorID	2.978 s	5.810 s	-95.1%

Le résultat de -95.1% s'explique par le contexte d'exécution : le dataset brut bénéficiait d'un cache Spark chaud, tandis que le dataset nettoyé était nouvellement créé. Sur des volumes réels de l'ordre du téraoctet, le gain du nettoyage se manifeste principalement par la réduction des shuffles réseau lors des agrégations — avantage non mesurable à cette échelle sur un environnement Colab local.

7.3 Temps d'exécution par étape

Étape du pipeline	Temps mesuré	Complexité Spark
Profilage (df.summary)	~45 s	$O(n)$ — une seule passe
Calcul Z-Score	~8 s	$O(n)$ — agrégation distribuée
Nettoyage logique (5 filtres)	12.65 s	$O(n)$ — transformations locales
Comparaison avant/après	~15 s	$O(n)$ — deux agrégations
Analyse taux de rejet	~20 s	$O(n \log n)$ — groupBy + count

8. Conclusion

8.1 Bilan technique

- Détection de 35 154 outliers statistiques par Z-Score (1.15% du dataset).
- Application de 5 règles de filtrage logique pour éliminer les incohérences physiques.
- Rejet total de 219 087 lignes — taux de rejet de 7.14%.
- Erreur statistique quantifiée : +3.08% sur la moyenne, +30.77% sur la variance sans nettoyage.
- Biais capteur identifié : Vendor 2 responsable de 82.2% des erreurs.

8.2 Leçon fondamentale : Garbage In, Garbage Out

Sans pipeline de nettoyage, tout modèle prédictif, système de tarification ou indicateur décisionnel construit sur des données brutes intègre structurellement des erreurs. La moyenne des tarifs était surestimée de 3.08% et la variance de 30.77% — ce qui aurait conduit à des décisions potentiellement coûteuses dans n'importe quel contexte opérationnel.

8.3 Impact pour la Mauritanie — SMELEC et souveraineté numérique

- Bloquer automatiquement toute facturation basée sur une valeur aberrante (ex : 5 000 kWh/jour).
- Identifier les compteurs défectueux par biais de capteur, comme le Vendor 2 dans notre analyse.
- Réduire le volume de réclamations et améliorer la confiance numérique entre la société et les citoyens.
- Garantir que les indicateurs économiques nationaux (ANSADE) ne sont pas faussés par des erreurs de saisie.

Un bon Data Engineer ne se contente pas de traiter la donnée — il en garantit la véracité. C'est cette véracité qui fonde la souveraineté numérique d'un pays.